UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS

Facultad de Ingeniería
Universidad Distrital Francisco José de Caldas

Informe de avance de datos estadísticos

Análisis estadístico descriptivo de 60 datos simulados con Python

Autores:

Luis Fernando Rojas Rada – 20222020242
Alejandro Sánchez Escobar – 20222020252

Probabilidad y Estadística

21 de abril de 2026

1. Introducción

La estadística descriptiva constituye una herramienta fundamental para organizar, resumir y analizar conjuntos de datos, ya que permite identificar patrones, tendencias y niveles de dispersión dentro de una muestra. Su aplicación resulta especialmente importante en contextos académicos, científicos y tecnológicos, donde se requiere transformar datos numéricos en información útil para su interpretación.

En el presente informe se desarrolla un análisis estadístico descriptivo a partir de una muestra simulada digitalmente de 60 datos enteros comprendidos entre 00 y 99. El contexto seleccionado corresponde a los tiempos de respuesta, medidos en segundos, de 60 estudiantes al resolver un cuestionario corto de estadística en formato digital. Este tema fue elegido por ser coherente con el entorno académico y por permitir aplicar de manera clara las herramientas vistas en clase.

Es importante destacar que, cumpliendo con los requerimientos de la asignatura, tanto para la generación aleatoria de los datos como para la construcción de las tablas de frecuencias y las representaciones gráficas, se emplearon herramientas computacionales, específicamente el lenguaje de programación Python y sus bibliotecas especializadas en ciencia de datos (`numpy`, `pandas`, `matplotlib` y `seaborn`).

A lo largo del informe se presentan la organización de los datos, la construcción de tablas de frecuencia, el desarrollo de representaciones gráficas y el cálculo detallado de medidas de tendencia central, dispersión y posición. Finalmente, se realiza una interpretación estadística integral de los resultados obtenidos.

2. Objetivos

2.1. Objetivo general

Analizar estadísticamente una muestra de 60 datos simulados mediante tablas, gráficos y medidas descriptivas procesadas computacionalmente, con el propósito de interpretar su comportamiento y aplicar los conceptos desarrollados en el curso de Probabilidad y Estadística.

2.2. Objetivos específicos

- Organizar los datos en tablas estadísticas adecuadas para su análisis apoyándose en bibliotecas de Python.
- Calcular medidas de tendencia central como media, mediana y moda.
- Hallar medidas de dispersión como rango, varianza, desviación estándar, coeficiente de variación y error estándar.
- Determinar medidas de posición como cuartiles, deciles y percentiles.
- Representar la información mediante histogramas, gráficos de barras, polígono de frecuencias, ojiva y diagrama de caja y bigotes haciendo uso de herramientas digitales.
- Interpretar los resultados obtenidos de forma numérica y gráfica.

3. Planteamiento del problema

En ambientes académicos mediados por herramientas digitales, el tiempo de respuesta de un estudiante frente a una actividad puede dar información relevante sobre su ritmo de trabajo, su comprensión del tema y su capacidad de interacción con el medio virtual. Por ello, resulta pertinente analizar una muestra de tiempos de respuesta para describir su comportamiento estadístico.

En este trabajo se plantea el estudio de 60 tiempos de respuesta simulados, medidos en segundos, correspondientes a 60 estudiantes que resolvieron un cuestionario corto de estadística. A partir de estos datos se busca responder la siguiente pregunta: *¿cómo se distribuyen los tiempos de respuesta de los estudiantes y qué medidas estadísticas permiten describir e interpretar adecuadamente esta distribución?*

4. Marco teórico

La estadística descriptiva es la rama de la estadística encargada de recolectar, organizar, presentar y resumir un conjunto de datos. Su objetivo es convertir una gran cantidad de observaciones numéricas en información comprensible, útil y ordenada.

Entre los conceptos principales empleados en este informe se encuentran:

- **Tabla de frecuencias:** organiza los datos en intervalos y muestra cuántas observaciones hay en cada clase.
- **Media aritmética:** representa el promedio del conjunto de datos.
- **Mediana:** corresponde al valor central cuando los datos se ordenan de menor a mayor.

- **Moda:** es el valor o conjunto de valores que más se repiten.
- **Rango:** es la diferencia entre el valor máximo y el valor mínimo.
- **Varianza:** mide la dispersión cuadrática de los datos respecto a la media.
- **Desviación estándar:** corresponde a la raíz cuadrada de la varianza.
- **Coeficiente de variación:** expresa la dispersión relativa en porcentaje.
- **Error estándar:** estima la variabilidad de la media muestral.
- **Cuartiles, deciles y percentiles:** dividen la distribución ordenada en partes iguales y permiten ubicar la posición relativa de los datos.
- **Asimetría y curtosis:** describen la forma de la distribución.
- **Valor mínimo y valor máximo:** son la observación más pequeña y la más grande del conjunto de datos, respectivamente. Delimitan el soporte empírico de la distribución.
- **Curtosis:** mide el grado de apuntamiento o achatamiento de la distribución en comparación con la distribución normal. Un valor positivo indica distribución leptocúrtica (más apuntada); un valor negativo indica distribución platicúrtica (más achatada); y un valor igual a cero corresponde a una distribución mesocúrtica.

Estas herramientas permiten describir tanto la localización de la muestra como su nivel de dispersión y la forma general de su distribución.

5. Datos de la muestra y proceso de muestreo

5.1. Proceso de recolección y muestreo

De acuerdo con los lineamientos establecidos para este avance, la recolección de información no se realizó mediante la observación de un fenómeno real, sino a través de un proceso de **simulación digital controlada** utilizando el lenguaje de programación Python. El procedimiento consistió en generar un conjunto de 60 números enteros, seleccionados al azar mediante el uso de bibliotecas computacionales (como `numpy.random` o `random.randint`), bajo la estricta condición de estar comprendidos entre el 00 y el 99.

Desde el punto de vista teórico, este método de generación de datos equivale a un **muestreo probabilístico de tipo aleatorio simple**. Se clasifica como probabilístico porque, al elegir los números de forma aleatoria estructurada, cualquier valor entero dentro del intervalo [00, 99] tenía teóricamente la misma probabilidad de ser seleccionado para conformar la muestra, evitando así un sesgo de selección intencional.

5.2. Contextualización de los datos

Para dotar a la muestra de un significado práctico y coherente que permitiera un análisis lógico, se definió de manera autónoma el siguiente contexto: los 60 valores generados representan los *tiempos de respuesta, medidos en segundos*, que tardaron 60 estudiantes universitarios en completar un cuestionario corto de estadística en una plataforma digital.

Los 60 datos (en segundos) obtenidos tras la simulación son los siguientes:

$$12, 18, 21, 22, 24, 25, 27, 27, 29, 30, 31, 33, 34, 35, 36, 38, 39, 40, 41, 41,$$

$$42, 43, 44, 45, 46, 47, 47, 48, 49, 50, 50, 51, 52, 53, 54, 54, 55, 56, 57, 58,$$

$$59, 60, 60, 61, 62, 63, 64, 65, 66, 68, 70, 72, 74, 76, 78, 80, 82, 85, 88, 92$$

Al ordenar la información, se identifica que el valor mínimo es 12 y el valor máximo es 92, lo cual confirma que todos los datos cumplen con la restricción inicial de estar entre 00 y 99.

6. Tabla de frecuencias

Con el fin de resumir y organizar la información, los datos se agruparon en intervalos de amplitud 10 (proceso estructurado computacionalmente con la ayuda de `pandas`). Para cada intervalo se calculó la frecuencia absoluta, la frecuencia acumulada, la frecuencia relativa y la frecuencia relativa acumulada.

Cuadro 1: Tabla de frecuencias agrupadas

Intervalo	Marca de clase	f_i	F_i	h_i	H_i
10–19	14.5	2	2	0.0333	0.0333
20–29	24.5	7	9	0.1167	0.1500
30–39	34.5	8	17	0.1333	0.2833
40–49	44.5	12	29	0.2000	0.4833
50–59	54.5	12	41	0.2000	0.6833
60–69	64.5	9	50	0.1500	0.8333
70–79	74.5	5	55	0.0833	0.9167
80–89	84.5	4	59	0.0667	0.9833
90–99	94.5	1	60	0.0167	1.0000

La tabla anterior permite observar que los intervalos con mayor frecuencia son 40–49 y 50–59, cada uno con 12 observaciones. Esto indica que la mayor concentración de datos se ubica en la zona central de la distribución.

7. Desarrollo manual de las medidas estadísticas

7.1. Media aritmética

La media aritmética se calcula mediante la expresión:

$$\bar{x} = \frac{\sum x_i}{n}$$

En este caso, se realiza la suma completa de los 60 datos:

$$\begin{aligned}\sum x_i = 12 + 18 + 21 + 22 + 24 + 25 + 27 + 27 + 29 + 30 \\ + 31 + 33 + 34 + 35 + 36 + 38 + 39 + 40 + 41 + 41 \\ + 42 + 43 + 44 + 45 + 46 + 47 + 47 + 48 + 49 + 50 \\ + 50 + 51 + 52 + 53 + 54 + 54 + 55 + 56 + 57 + 58 \\ + 59 + 60 + 60 + 61 + 62 + 63 + 64 + 65 + 66 + 68 \\ + 70 + 72 + 74 + 76 + 78 + 80 + 82 + 85 + 88 + 92\end{aligned}$$

$$\sum x_i = 3029$$

Como el tamaño de la muestra es:

$$n = 60$$

entonces:

$$\bar{x} = \frac{3029}{60} = 50.4833$$

Aproximando a dos decimales:

$$\bar{x} = 50.48$$

Por lo tanto, el promedio de tiempo de respuesta de los estudiantes fue de 50.48 segundos.

7.2. Mediana

Para hallar la mediana, primero se ordenan los datos de menor a mayor. Como la cantidad de datos es par, la mediana corresponde al promedio entre los valores ubicados en las posiciones 30 y 31.

$$\frac{n}{2} = 30, \qquad \frac{n}{2} + 1 = 31$$

En la muestra ordenada:

$$x_{30} = 50, \qquad x_{31} = 50$$

Por tanto:

$$Md = \frac{x_{30} + x_{31}}{2} = \frac{50 + 50}{2} = 50$$

La mediana muestra que el punto central de la distribución es 50 segundos.

7.3. Moda

La moda es el valor que más se repite dentro del conjunto de datos. Al revisar la muestra se observa que los números 27, 41, 47, 50, 54 y 60 aparecen dos veces, mientras que el resto de los datos aparece una sola vez.

Por consiguiente, la distribución es **multimodal** y sus modas son:

$$Mo = \{27,\ 41,\ 47,\ 50,\ 54,\ 60\}$$

7.4. Rango

El rango se obtiene restando el valor mínimo al valor máximo de la muestra:

$$R = x_{\text{máx}} - x_{\text{mín}}$$

Sustituyendo:

$$R = 92 - 12 = 80$$

Esto significa que entre el menor y el mayor tiempo de respuesta existe una diferencia de 80 segundos.

7.5. Valor mínimo y valor máximo

El **valor mínimo** ($x_{\text{mín}}$) es la observación más pequeña del conjunto de datos, y el **valor máximo** ($x_{\text{máx}}$) es la observación más grande. Ambos se identifican directamente a partir de la muestra ordenada de menor a mayor:

$$x_{\text{mín}} = \text{mín}\{x_1, x_2, \ldots, x_n\} = 12$$

$$x_{\text{máx}} = \text{máx}\{x_1, x_2, \ldots, x_n\} = 92$$

Estos dos valores delimitan el soporte empírico de la distribución y sirven de base para el cálculo del rango. Se verifica que ambos se encuentran dentro del intervalo permitido de [00, 99].

7.6. Varianza muestral

La varianza muestral se calculó con la fórmula abreviada:

$$s^2 = \frac{\sum x_i^2 - \frac{(\sum x_i)^2}{n}}{n-1}$$

Para aplicar la fórmula, primero se calcula la suma de los cuadrados de todos los datos:

$$\begin{aligned}
\sum x_i^2 = {} & 12^2 + 18^2 + 21^2 + 22^2 + 24^2 + 25^2 + 27^2 + 27^2 + 29^2 + 30^2 \\
& + 31^2 + 33^2 + 34^2 + 35^2 + 36^2 + 38^2 + 39^2 + 40^2 + 41^2 + 41^2 \\
& + 42^2 + 43^2 + 44^2 + 45^2 + 46^2 + 47^2 + 47^2 + 48^2 + 49^2 + 50^2 \\
& + 50^2 + 51^2 + 52^2 + 53^2 + 54^2 + 54^2 + 55^2 + 56^2 + 57^2 + 58^2 \\
& + 59^2 + 60^2 + 60^2 + 61^2 + 62^2 + 63^2 + 64^2 + 65^2 + 66^2 + 68^2 \\
& + 70^2 + 72^2 + 74^2 + 76^2 + 78^2 + 80^2 + 82^2 + 85^2 + 88^2 + 92^2
\end{aligned}$$

$$\sum x_i^2 = 173473$$

Ahora se reemplaza en la fórmula:

$$s^2 = \frac{173473 - \frac{(3029)^2}{60}}{59}$$

$$s^2 = \frac{173473 - \frac{9174841}{60}}{59}$$

$$s^2 = \frac{173473 - 152914.0167}{59}$$

$$s^2 = \frac{20558.9833}{59} = 348.4573$$

Aproximando:

$$s^2 = 348.46$$

7.7. Desviación estándar

La desviación estándar se obtiene calculando la raíz cuadrada de la varianza:

$$s = \sqrt{348.4573} = 18.6670$$

Aproximando a dos decimales:

$$s = 18.67$$

Esto quiere decir que, en promedio, los datos se alejan 18.67 segundos respecto a la media.

7.8. Coeficiente de variación

El coeficiente de variación se calcula con la fórmula:

$$CV = \frac{s}{\bar{x}} \times 100$$

Sustituyendo los valores obtenidos:

$$CV = \frac{18.67}{50.48} \times 100 = 36.98\,\%$$

Este resultado indica que la dispersión relativa de la muestra es moderada.

7.9. Error estándar

El error estándar se calcula como:

$$SE = \frac{s}{\sqrt{n}}$$

Entonces:

$$SE = \frac{18.67}{\sqrt{60}}$$

$$SE = \frac{18.67}{7.746} = 2.41$$

Este valor representa la variabilidad de la media muestral con respecto a una posible media poblacional.

7.10. Curtosis

La curtosis es una medida de forma que indica el grado de apuntamiento o achatamiento de la distribución en relación con la distribución normal. Se emplea el **coeficiente de curtosis muestral de Fisher** (exceso de curtosis), cuya fórmula es:

$$g_2 = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \cdot \frac{\sum_{i=1}^{n}(x_i - \bar{x})^4}{s^4} - \frac{3(n-1)^2}{(n-2)(n-3)}$$

donde $n = 60$, $\bar{x} = 50.48$ y $s = 18.67$.

Paso 1. Suma de las cuartas potencias de las desviaciones respecto a la media:

$$\sum_{i=1}^{60}(x_i - \bar{x})^4 = 17{,}218{,}098.40$$

Paso 2. Cuarta potencia de la desviación estándar:

$$s^4 = (18.67)^4 = 121{,}614.11$$

Paso 3. Factor de corrección muestral:

$$\frac{n(n+1)}{(n-1)(n-2)(n-3)} = \frac{60 \times 61}{59 \times 58 \times 57} = \frac{3{,}660}{195{,}006} = 0.018769$$

Paso 4. Primer término de la fórmula:

$$0.018769 \times \frac{17{,}218{,}098.40}{121{,}614.11} = 0.018769 \times 141.58 = 2.657$$

Paso 5. Término de corrección:

$$\frac{3(n-1)^2}{(n-2)(n-3)} = \frac{3 \times 59^2}{58 \times 57} = \frac{10{,}443}{3{,}306} = 3.159$$

Paso 6. Coeficiente de curtosis:

$$\boxed{g_2 = 2.657 - 3.159 = -0.50}$$

Interpretación: como $g_2 = -0.50 < 0$, la distribución es **platicúrtica**. Esto significa que la curva es más achatada que la distribución normal, con menor concentración de datos alrededor de la media y colas relativamente más cortas y uniformes.

8. Medidas de posición

8.1. Cuartiles

La posición de los cuartiles se calcula mediante:

$$L_{Q_k} = \frac{k(n+1)}{4}$$

Primer cuartil:

$$L_{Q_1} = \frac{1(60+1)}{4} = 15.25$$

Esto significa que el primer cuartil se encuentra entre las posiciones 15 y 16 del arreglo ordenado:

$$x_{15} = 36, \qquad x_{16} = 38$$

Interpolando:

$$Q_1 = 36 + 0.25(38 - 36) = 36.50$$

Segundo cuartil:

$$L_{Q_2} = \frac{2(60+1)}{4} = 30.5$$

Está entre los valores:

$$x_{30} = 50, \qquad x_{31} = 50$$

Por tanto:

$$Q_2 = 50$$

Tercer cuartil:

$$L_{Q_3} = \frac{3(60+1)}{4} = 45.75$$

Se encuentra entre las posiciones 45 y 46:

$$x_{45} = 62, \qquad x_{46} = 63$$

Entonces:

$$Q_3 = 62 + 0.75(63 - 62) = 62.75$$

8.2. Rango intercuartílico

El rango intercuartílico se calcula como:

$$IQR = Q_3 - Q_1$$

$$IQR = 62.75 - 36.50 = 26.25$$

Este resultado indica que el 50 % central de los datos está contenido en un intervalo de 26.25 segundos.

8.3. Deciles

La posición de los deciles se obtiene con:

$$L_{D_k} = \frac{k(n+1)}{10}$$

Primer decil:

$$L_{D_1} = \frac{1(61)}{10} = 6.1$$

Se ubica entre los datos:

$$x_6 = 25, \qquad x_7 = 27$$

Entonces:

$$D_1 = 25 + 0.1(27 - 25) = 25.2$$

Quinto decil:

$$L_{D_5} = \frac{5(61)}{10} = 30.5$$

Por tanto:

$$D_5 = 50$$

Noveno decil:

$$L_{D_9} = \frac{9(61)}{10} = 54.9$$

Se ubica entre:

$$x_{54} = 76, \qquad x_{55} = 78$$

Entonces:

$$D_9 = 76 + 0.9(78 - 76) = 77.8$$

8.4. Percentiles

La posición de los percentiles se calcula mediante:

$$L_{P_k} = \frac{k(n+1)}{100}$$

Los percentiles más representativos de esta distribución son:

$$P_{25} = 36.50, \qquad P_{50} = 50, \qquad P_{75} = 62.75$$

Estos valores coinciden con los cuartiles Q_1, Q_2 y Q_3, respectivamente.

9. Forma de la distribución

La distribución presenta una ligera asimetría positiva, ya que los valores altos se extienden un poco más hacia la derecha. Esto se relaciona con la presencia de observaciones como 80, 82, 85, 88 y 92, que amplían la cola superior de la muestra.

Asimismo, la curtosis obtenida indica que la distribución no es excesivamente apuntada, sino más bien moderada en su forma general. En conjunto, estos resultados son coherentes con una muestra centrada alrededor de 50 segundos y con dispersión media.

10. Representaciones gráficas

A continuación se presentan las gráficas estadísticas construidas a partir de la muestra analizada, las cuales fueron procesadas y renderizadas utilizando bibliotecas de Python como `matplotlib` y `seaborn`.

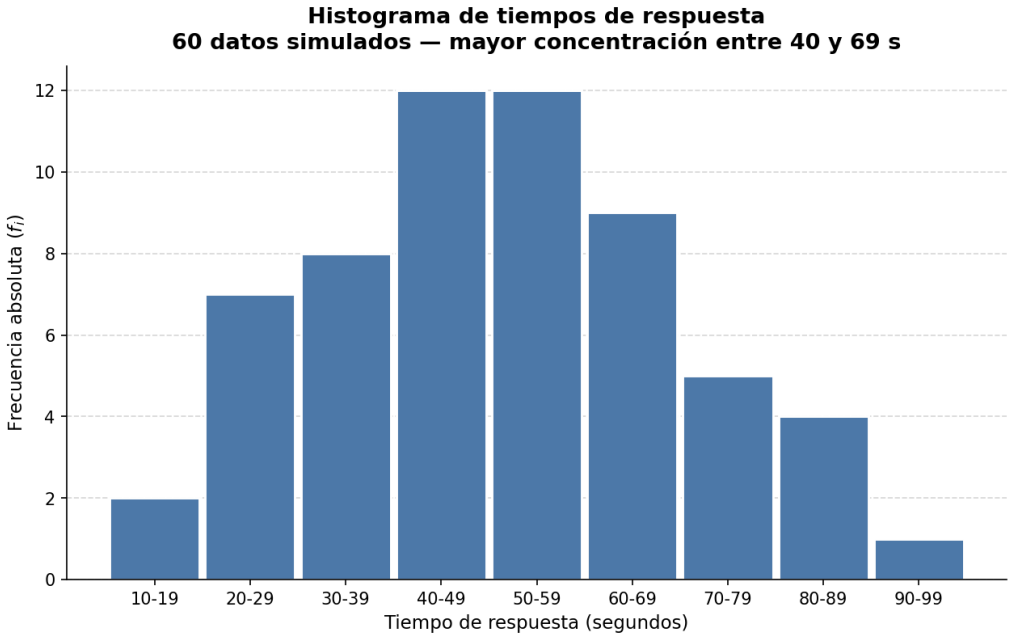

Figura 1: Histograma de los tiempos de respuesta

El histograma evidencia que la mayor concentración de datos se ubica entre 40 y 69 segundos, lo que confirma que la distribución se concentra en la zona media.

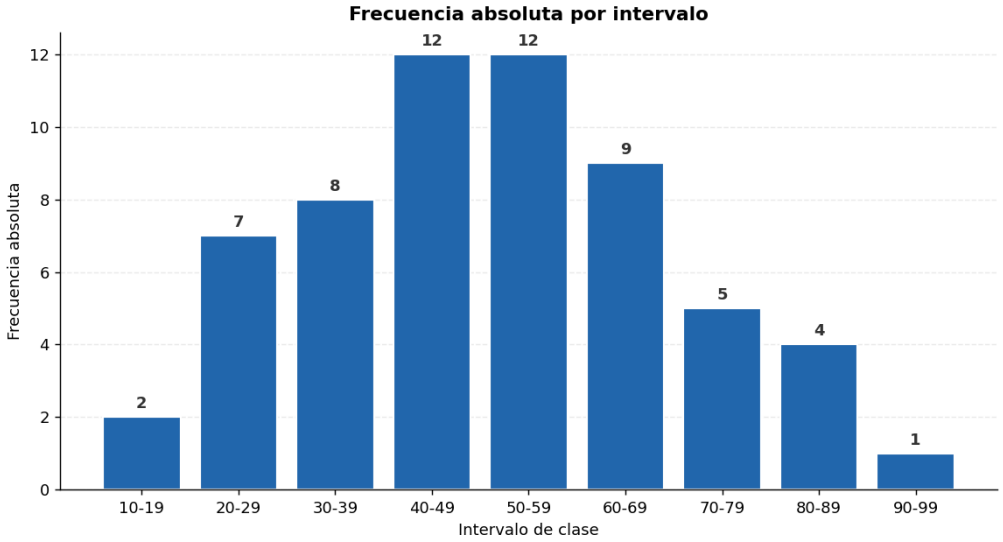

Figura 2: Gráfico de barras de frecuencias por intervalo

El gráfico de barras permite comparar con claridad la frecuencia absoluta de cada intervalo y muestra que los intervalos 40–49 y 50–59 son los más representativos de la muestra.

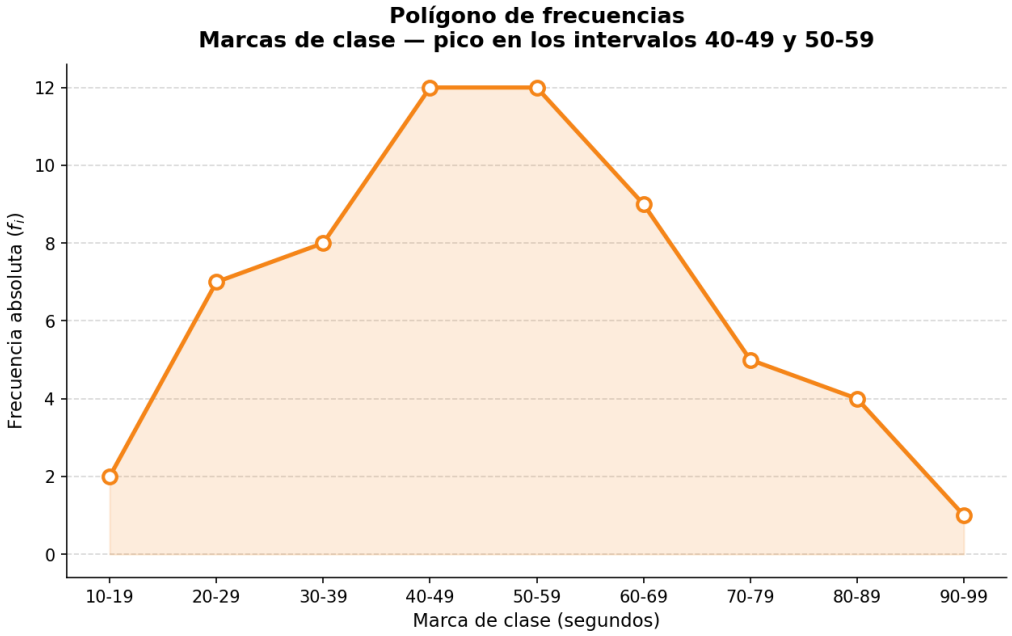

Figura 3: Polígono de frecuencias

El polígono de frecuencias muestra un aumento progresivo hasta alcanzar la mayor concentración en la parte central y luego una disminución hacia los extremos.

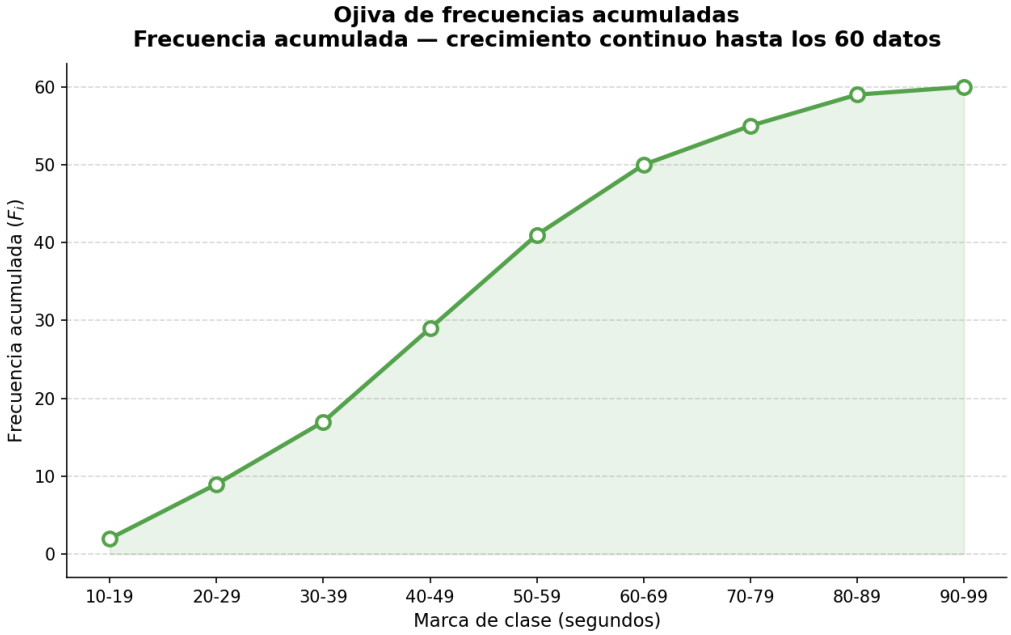

Figura 4: Ojiva de frecuencias acumuladas

La ojiva permite observar cómo se va acumulando la frecuencia a medida que avanzan los intervalos y confirma que hacia la zona media ya se ha reunido más de la mitad de las observaciones.

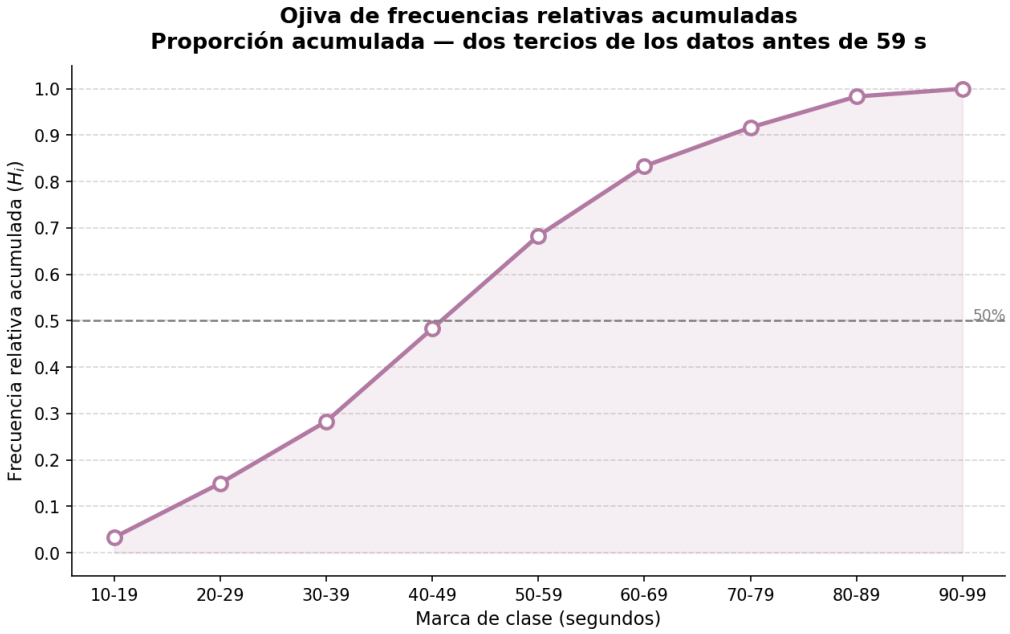

Figura 5: Ojiva de frecuencias relativas acumuladas

La ojiva relativa facilita la interpretación porcentual de los datos acumulados y complementa el análisis de la distribución por intervalos.

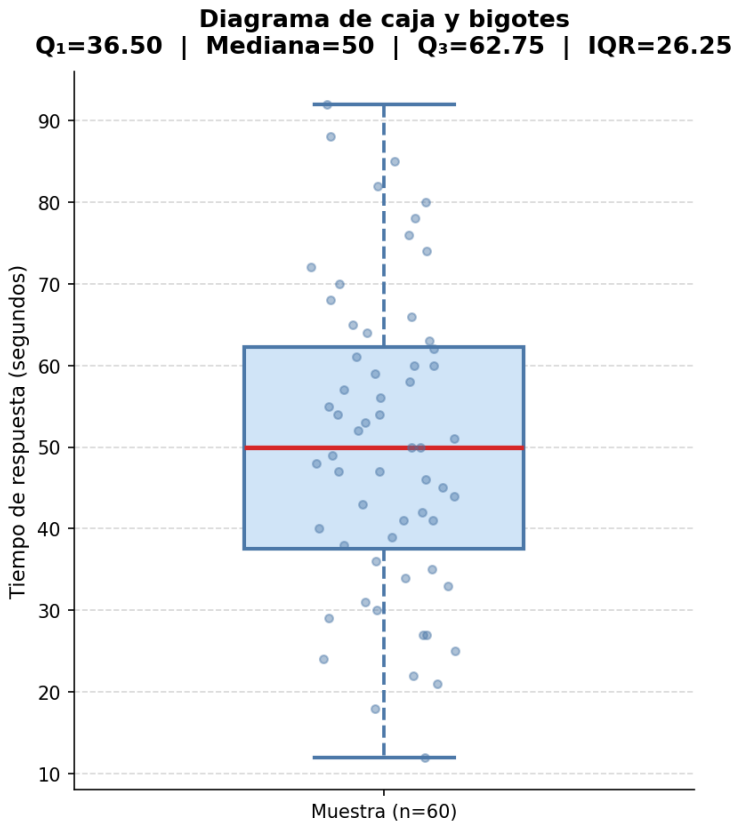

Figura 6: Diagrama de caja y bigotes

El diagrama de caja y bigotes resume visualmente los cuartiles, la mediana y la dispersión de la muestra, mostrando una estructura relativamente estable en el centro y sin valores atípicos extremos.

11. Interpretación general de los resultados

Los resultados obtenidos permiten concluir que la muestra presenta una clara concentración alrededor de 50 segundos, valor que coincide aproximadamente con la media y exactamente con la mediana. Esto indica que el tiempo típico de respuesta de los estudiantes se encuentra en la zona central de la distribución.

La dispersión de la muestra puede considerarse moderada, ya que la desviación estándar fue de 18.67 y el coeficiente de variación de 36.98 %. Además, el rango intercuartílico de 26.25 evidencia que el 50 % central de los datos se mantiene relativamente concentrado.

Desde el punto de vista gráfico, el histograma, el gráfico de barras y el polígono de frecuencias muestran una distribución con mayor densidad en los intervalos 40–49 y 50–59. Por su parte, la ojiva confirma el comportamiento acumulado de los datos, mientras que el diagrama de caja refuerza la interpretación de una distribución centrada y con ligera asimetría positiva.

12. Conclusiones

- La muestra simulada de 60 datos permitió aplicar de forma completa los principales conceptos de la estadística descriptiva empleando herramientas computacionales en Python.
- La media aritmética fue de 50.48 y la mediana fue de 50, lo cual indica una concentración de los tiempos de respuesta en la parte central de la distribución.
- La distribución es multimodal, debido a que varios valores presentaron la misma frecuencia máxima.
- La varianza muestral fue de 348.46 y la desviación estándar de 18.67, resultados que evidencian una dispersión moderada.
- El rango de 80 y el rango intercuartílico de 26.25 muestran que, aunque existen diferencias amplias entre los extremos, la mayor parte de los datos se concentra en una

zona central relativamente estable.

- Las gráficas elaboradas complementan adecuadamente el análisis numérico y permiten interpretar de forma visual la concentración, acumulación y dispersión de la muestra.

- El valor mínimo de la muestra fue de 12 segundos y el valor máximo de 92 segundos, lo que delimita un rango total de 80 segundos y confirma que todos los datos se encuentran dentro del intervalo permitido.

- El coeficiente de curtosis muestral obtenido fue $g_2 = -0.50$, lo que indica que la distribución es **platicúrtica**: ligeramente más achatada que la distribución normal, con menor concentración de datos en torno a la media y colas más uniformes.

13. Referencias

- Repositorio y código fuente del análisis computacional en Python: `https://github.com/LuisRojasR/biblioteca-prophet-python/blob/81d8f26f4ad77705a5e970e26182d5324295`
`Talleres%20Probabilidad%20y%20Estadistica/Informe_Estadistica-2.pdf`

- Triola, M. F. (2018). *Estadística* (12.ª ed.). Pearson Educación.

- Walpole, R. E., Myers, R. H., Myers, S. L., & Ye, K. (2012). *Probabilidad y estadística para ingeniería y ciencias* (9.ª ed.). Pearson Educación.